




FIAP






REDES NEURAIS & **DEEP LEARNING**



REDES NEURAIS **ARTIFICIAIS**

TRADITIONAL MACHINE LEARNING






DEEP LEARNING



PROBLEMAS COMPLEXOS

Técnicas de extração de características em imagens:



PROBLEMAS COMPLEXOS

Poodle ou frango frito?



PROBLEMAS COMPLEXOS

Cão ou rosca?



PROBLEMAS COMPLEXOS

Chihuahua ou muffin?



PROBLEMAS **COMPLEXOS**

Frango cru ou Donald Trump?



PROBLEMAS COMPLEXOS

Nós, humanos, após milhões de anos estamos começando a perder para as máquinas...

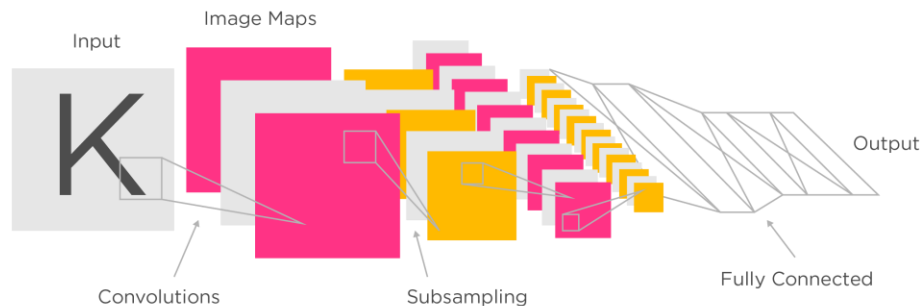


DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS

Arquitetura tradicional LeNet-5

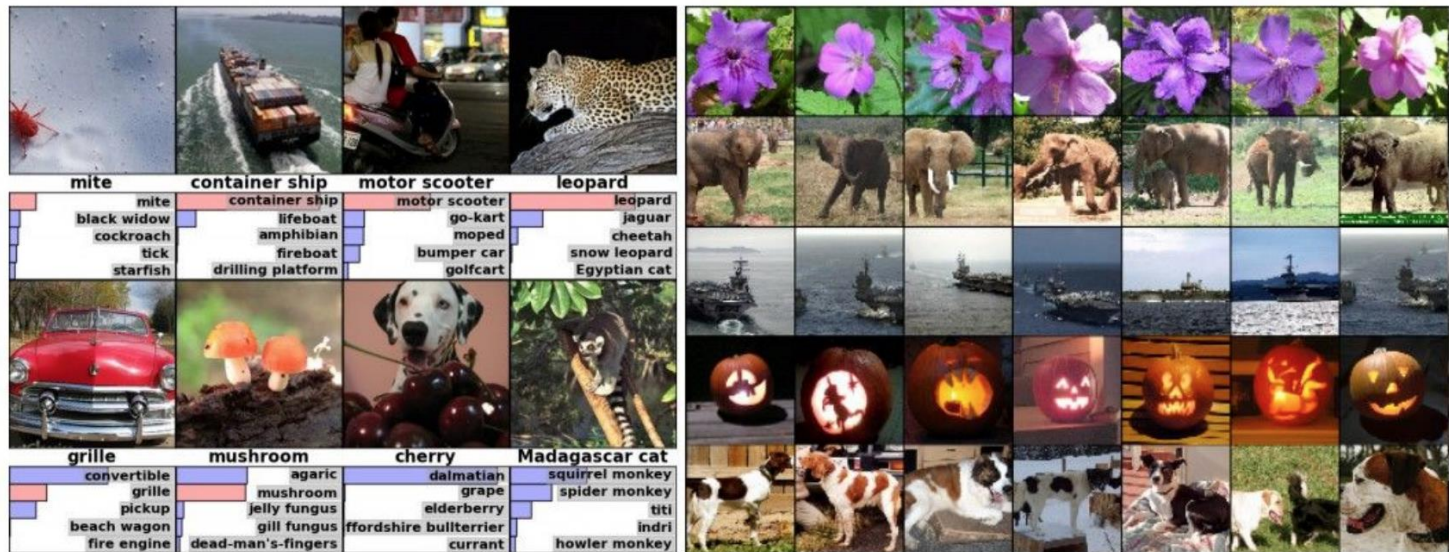
Review: LeNet-5

(LeCun et al., 1998)


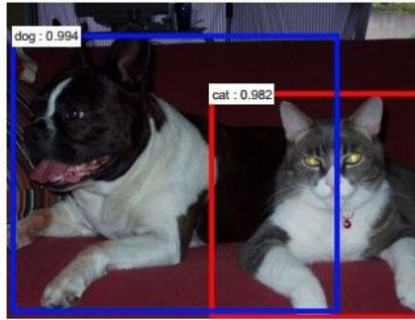



Conv filters were 5x5, applied at stride 1
Subsampling (Pooling) layers were 2x2 applied at stride 2
i.e. architecture is [CONV-POOL-CONV-POOL-FC-FC]

DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS



DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS



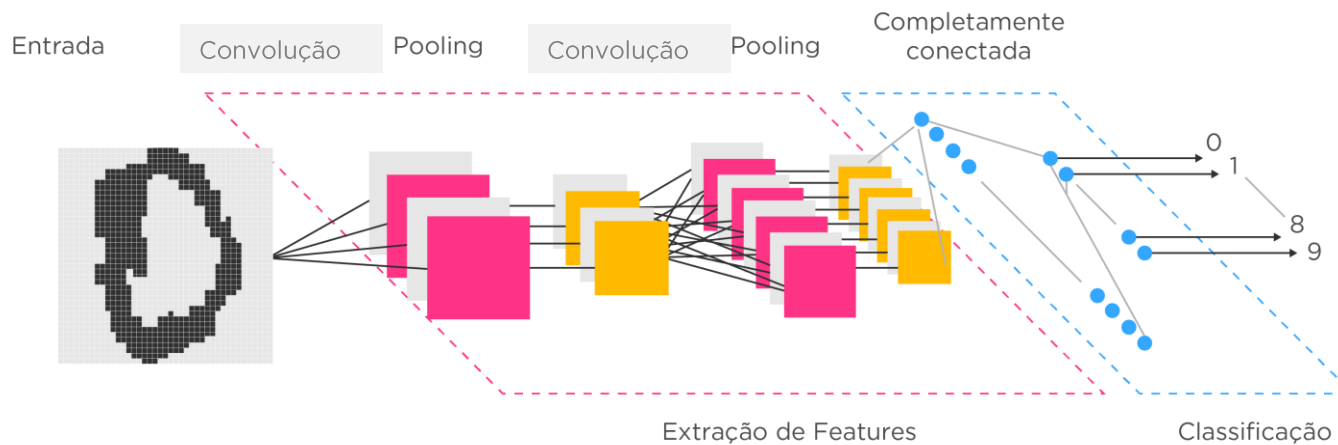
DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS



<https://experience.huia.haus/>

DEEP LEARNING – REDES NEURAIS CONVOLUCIONAIS

Arquitetura Geral





Fonte: MEDEIROS NETO, F. G.; PINTO JÚNIOR, R. F.; ROCHA, M. G. O. et al. Aprendizado profundo: conceitos, técnicas e estudo de caso de análise de imagens com Java. III Escola Regional de Informática do Piauí. **Livro Anais - Artigos e Minicursos**, v. 1, n. 1, pp. 465-486, jun. 2017.

REDES NEURAIS CONVOLUCIONAIS

CONVOLUÇÃO

A ideia é que uma **convolução** (ou um detector de atributos de rede neural local) mapeia uma dada região de certa imagem para um “mapa de atributos”.



REDES NEURAIS CONVOLUCIONAIS

CONVOLUÇÃO

A ideia é que uma **convolução** (ou um detector de atributos de rede neural local) mapeia uma dada região de certa imagem para um “mapa de atributos”.

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0


Image

4		

Convolved
Feature

REDES NEURAIS CONVOLUCIONAIS

CONVOLUÇÃO




- Imagem 32 x 32 x 3 → mantém a estrutura espacial preservada.

REDES NEURAIS CONVOLUCIONAIS

CONVOLUÇÃO

32x32x3 image



5x5x3




- Filtro.
- Convolve o filtro com a imagem.
- Por exemplo: “se desliza a imagem espacialmente, computando produtos escalares”.

REDES NEURAIS CONVOLUCIONAIS

CONVOLUÇÃO

32x32x3 image




5x5x3



- Os filtros sempre estendem a profundidade total do volume de entrada.
- Convolve o filtro com a imagem. Por exemplo: “Se desliza a imagem espacialmente, computando produtos de pontos”.

REDES NEURAIS CONVOLUCIONAIS

CONVOLUÇÃO

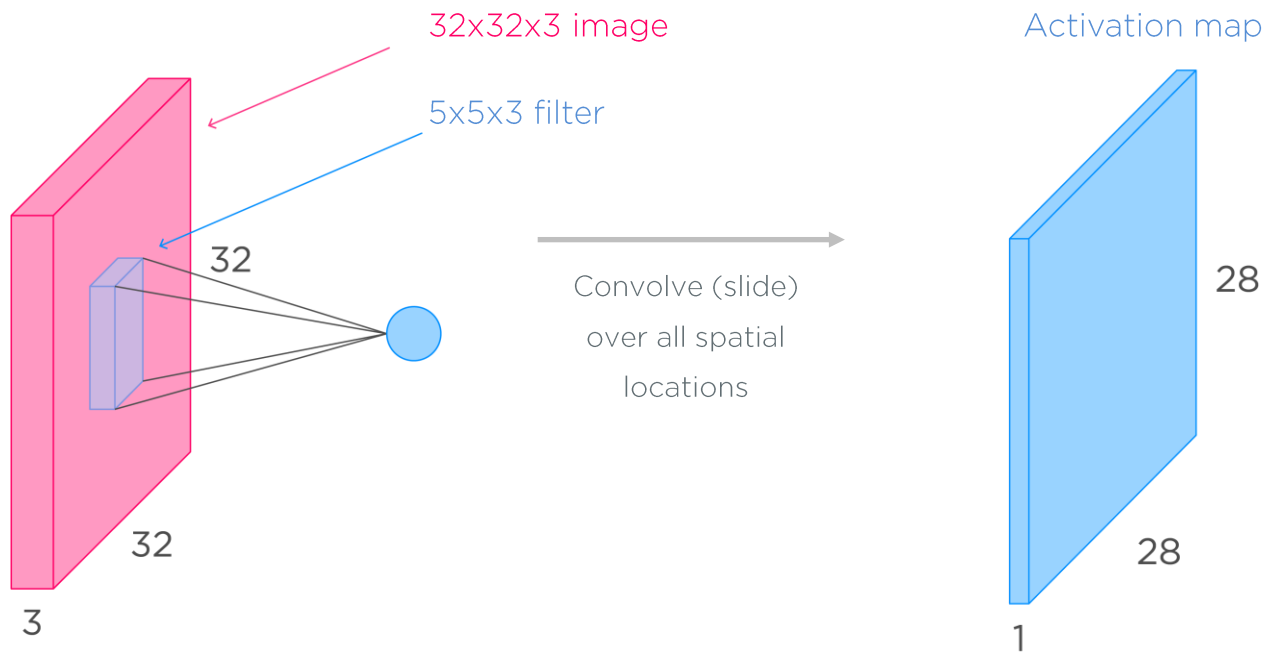


- 1 número: pedaço de $5 \times 5 \times 3$ da imagem (ou seja, $5 * 5 * 3 =$ produto escalar de 75 dimensões + bias).

$$w^T x + b$$

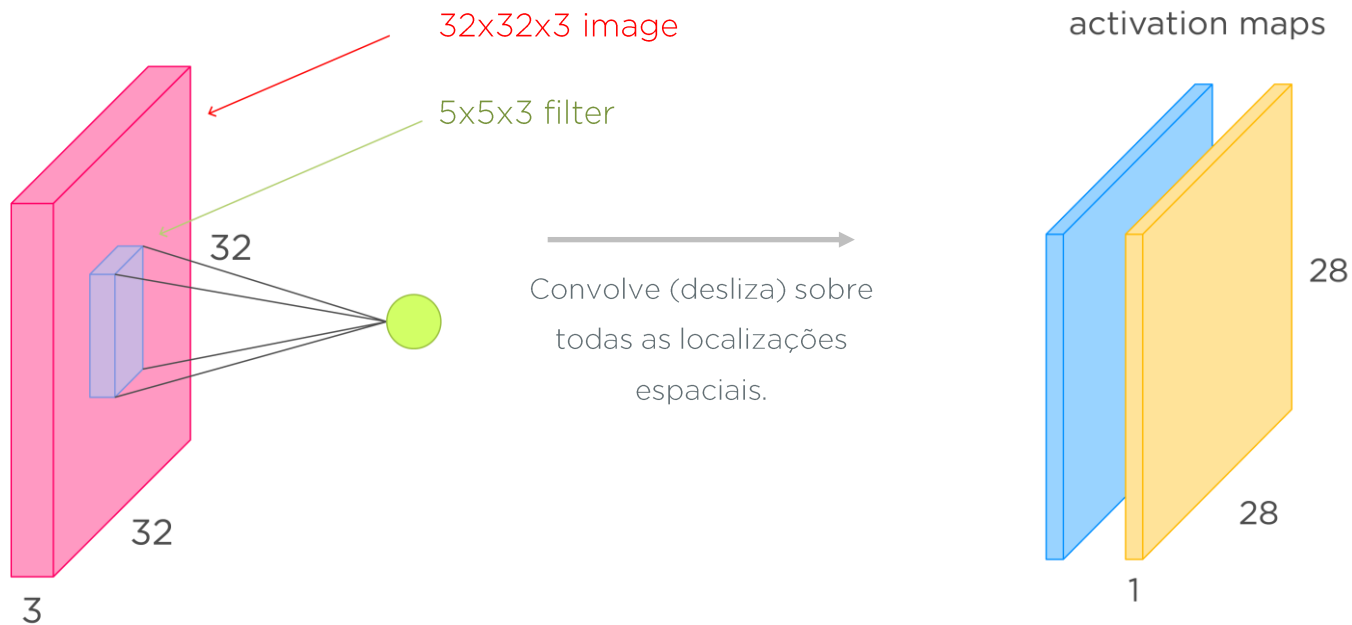
REDES NEURAIS CONVOLUCIONAIS

CONVOLUÇÃO



REDES NEURAIS CONVOLUCIONAIS


CONVOLUÇÃO



REDES NEURAIS CONVOLUCIONAIS


CONVOLUÇÃO

- Por exemplo, se tivéssemos seis filtros 5 x 5, obteríamos seis mapas de ativação separados.
- Receberíamos uma “nova imagem” de tamanho 28 x 28 x 6!



REDES NEURAIS CONVOLUCIONAIS

CONVOLUÇÃO




- ConvNets, então, são uma sequência de camadas de convolução intercaladas com funções de ativação.

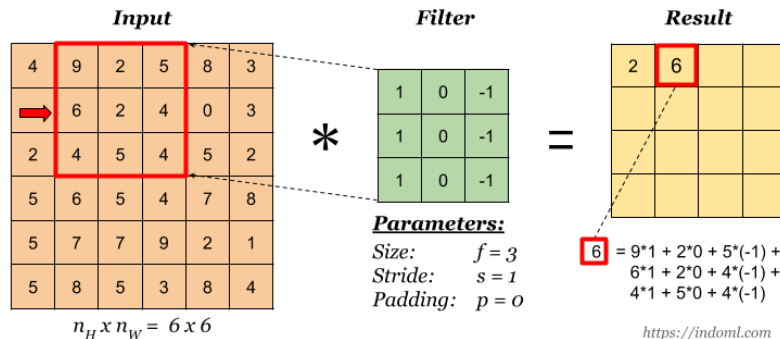
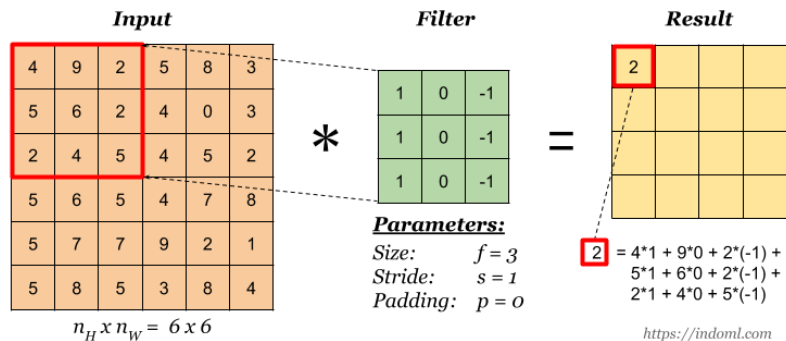
REDES NEURAIS CONVOLUCIONAIS

CONVOLUÇÃO

- ConvNets, então, são uma sequência de camadas de convolução intercaladas com funções de ativação.



EXEMPLOS DE CONVULÇÃO



EXEMPLOS DE CONVOLUÇÃO

-1	-1	-1	-1	-1	-1	-1	-1	-1
-1	1	-1	-1	-1	-1	-1	1	-1
-1	-1	1	-1	-1	-1	1	-1	-1
-1	-1	-1	1	-1	1	-1	-1	-1
-1	-1	-1	-1	1	-1	-1	-1	-1
-1	-1	-1	1	-1	1	-1	-1	-1
-1	-1	1	-1	-1	-1	1	-1	-1
-1	1	-1	-1	-1	-1	-1	1	-1
-1	-1	-1	-1	-1	-1	-1	-1	-1

Matriz de Entrada
(imagem)


1	-1	-1
-1	1	-1
-1	-1	1

Kernel

0.77	-0.11	0.11	0.33	0.55	-0.11	0.33
-0.11	1.00	-0.11	0.33	-0.11	0.11	-0.11
0.11	-0.11	1.00	-0.33	0.11	-0.11	0.55
0.33	0.33	-0.33	0.55	-0.33	0.33	0.33
0.55	-0.11	0.11	-0.33	1.00	-0.11	0.11
-0.11	0.11	-0.11	0.33	-0.11	1.00	-0.11
0.33	-0.11	0.55	0.33	0.11	-0.11	0.77

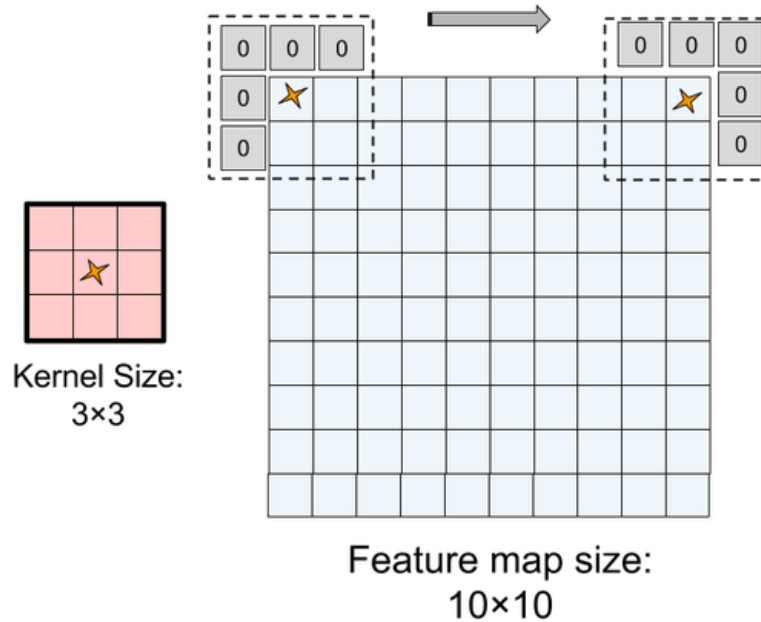
Mapa de Ativação

EXEMPLOS DE CONVOLUÇÃO



REDES NEURAIS CONVOLUCIONAIS

PADDING



REDES NEURAIS CONVOLUCIONAIS

PADDING

0	0	0	0	0	0	0
0	60	113	56	139	85	0
0	73	121	54	84	128	0
0	131	99	70	129	127	0
0	80	57	115	69	134	0
0	104	126	123	95	130	0
0	0	0	0	0	0	0

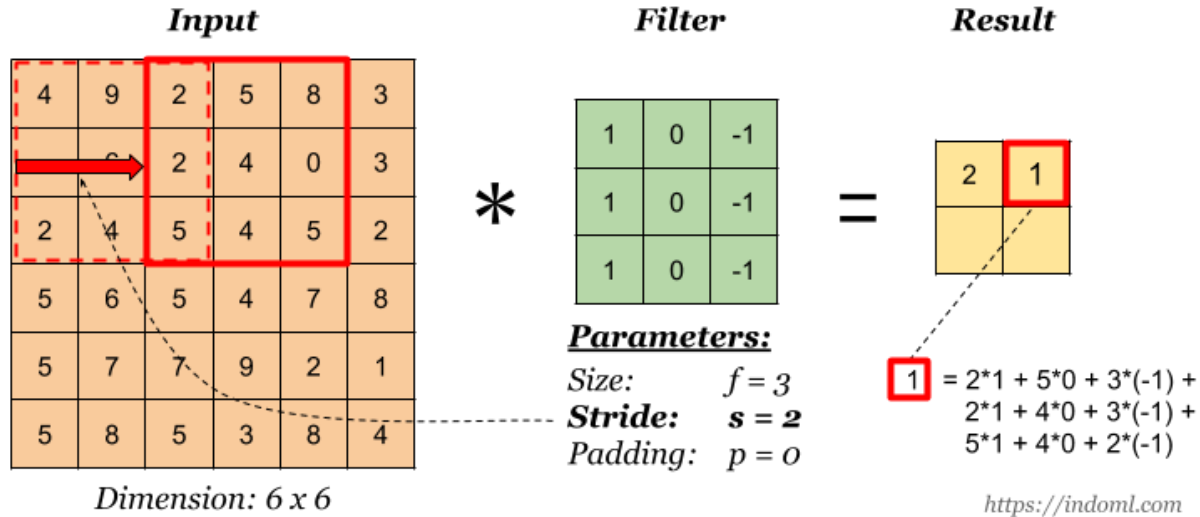
Kernel

0	-1	0
-1	5	-1
0	-1	0

114				

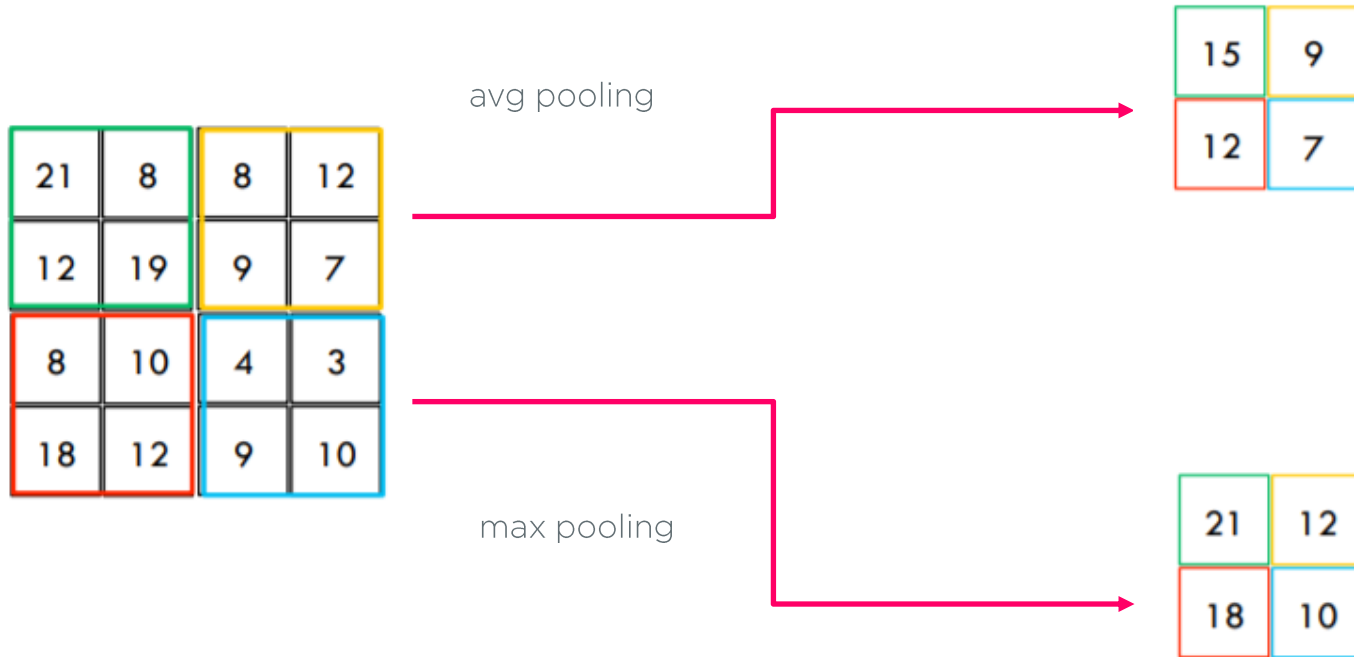
REDES NEURAIS CONVOLUCIONAIS

STRIDE



REDES NEURAIS CONVOLUCIONAIS

SUBAMOSTRAGEM




REDES NEURAIS CONVOLUCIONAIS

O que estamos fazendo com convolução e subamostragem?

Machine Learning

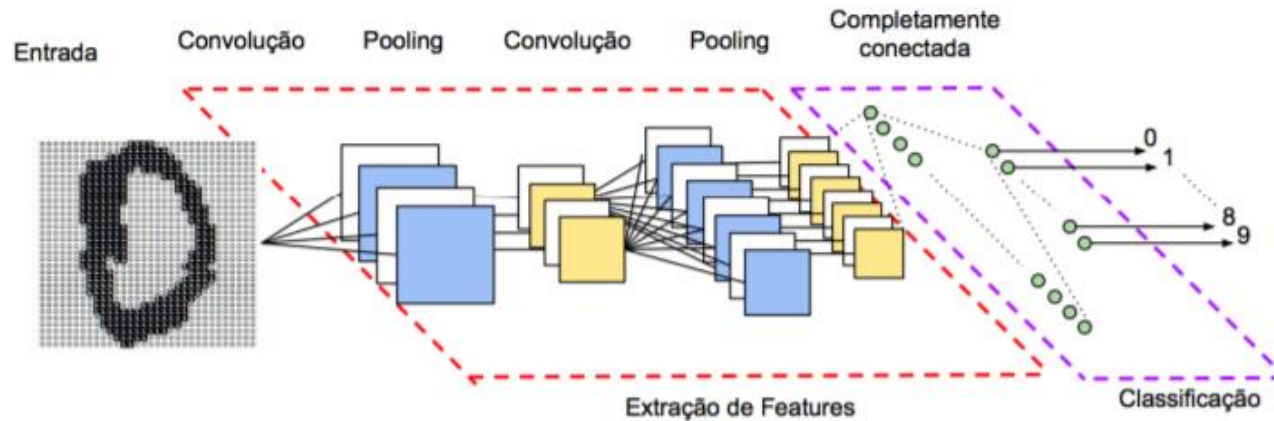


Deep Learning



REDES NEURAIS **CONVOLUCIONAIS**

ARQUITETURA GERAL




Fonte: MEDEIROS NETO, F. G.; PINTO JÚNIOR, R. F.; ROCHA, M. G. O. et al. Aprendizado profundo: conceitos, técnicas e estudo de caso de análise de imagens com Java. III Escola Regional de Informática do Piauí. **Livro Anais - Artigos e Minicursos**, v. 1, n. 1, pp. 465-486, jun. 2017.

REDES NEURAIS **CONVOLUCIONAIS**

ARQUITETURA GERAL

- Mas como as CNNs calibram os Kernels (filtros) durante o treinamento?



$$\partial W_{11} = X_{11} \partial h_{11} + X_{12} \partial h_{12} + X_{21} \partial h_{21} + X_{22} \partial h_{22}$$

$$\partial W_{12} = X_{12} \partial h_{11} + X_{13} \partial h_{12} + X_{22} \partial h_{21} + X_{23} \partial h_{22}$$

$$\partial W_{21} = X_{21} \partial h_{11} + X_{22} \partial h_{12} + X_{31} \partial h_{21} + X_{32} \partial h_{22}$$


$$\partial W_{22} = X_{22} \partial h_{11} + X_{23} \partial h_{12} + X_{32} \partial h_{21} + X_{33} \partial h_{22}$$

REDES NEURAIS **CONVOLUCIONAIS**

ARQUITETURAS CONHECIDAS

- Número de parâmetros: 60 mil

LeNet - 5




REDES NEURAIS CONVOLUCIONAIS

ARQUITETURAS CONHECIDAS

- Número de parâmetros: 60 milhões

AlexNet




Alex Krizhevsky, Geoffrey Hinton, and Ilya Sutskever Improving neural networks by preventing co-adaptation of feature detectors. arXiv preprint arXiv:1207.0580, 2012.

REDES NEURAIS **CONVOLUCIONAIS**

ARQUITETURAS CONHECIDAS

- Número de parâmetros: 138 milhões
- VGG-16 from Very Deep Convolutional Networks for Large-Scale Image Recognition




REDES NEURAIS **CONVOLUCIONAIS**

ARQUITETURAS CONHECIDAS

- Número de parâmetros: 25 milhões (ResNet50)

ResNet - Deep Residual Learning for Image Recognition




$$z^{[l+2]} = W^{[l+2]} a^{[l+1]} + b^{[l+2]}$$

$$a^{[l+2]} = g^{[l+2]}(z^{[l+2]} + a^{[l]})$$

REDES NEURAIS CONVOLUCIONAIS

ARQUITETURAS CONHECIDAS


ResNet – Deep Residual Learning for Image Recognition



REDES NEURAIS **CONVOLUCIONAIS**

ARQUITETURAS CONHECIDAS

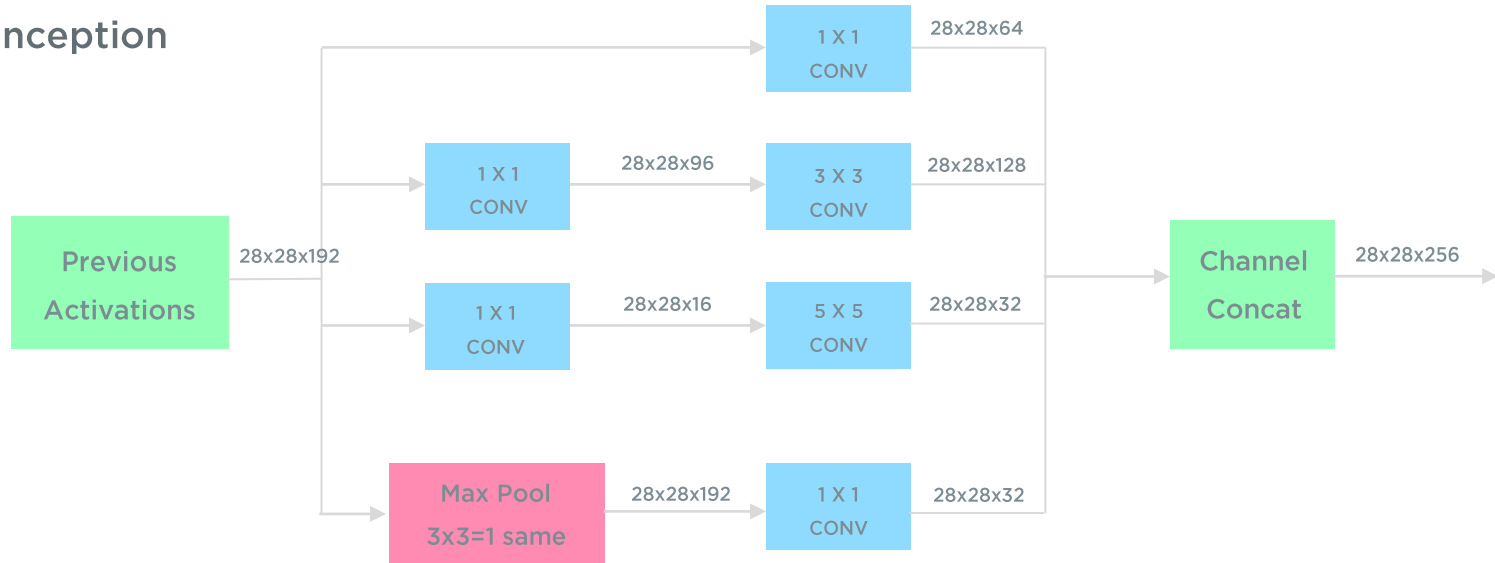
Inception



REDES NEURAIS **CONVOLUCIONAIS**

ARQUITETURAS CONHECIDAS

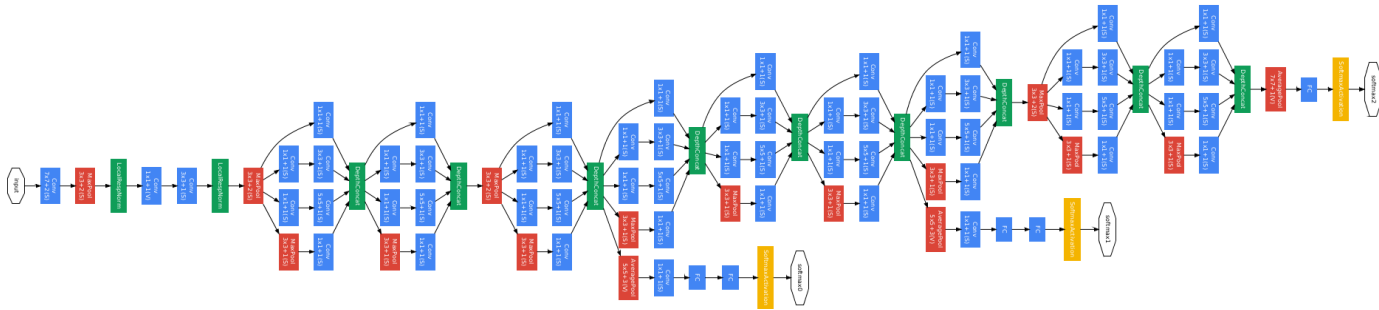
Inception



REDES NEURAIS **CONVOLUCIONAIS**

ARQUITETURAS CONHECIDAS

Inception – Google LeNet



REDES NEURAIS CONVOLUCIONAIS

- É possível realizar a convolução 1D?

10
50
60
10
20
40
30



REDES NEURAIS **CONVOLUCIONAIS**

- Em que cenários é interessante utilizar Conv 1D?
- Para que tipos de problemas?

DISCUSSÃO

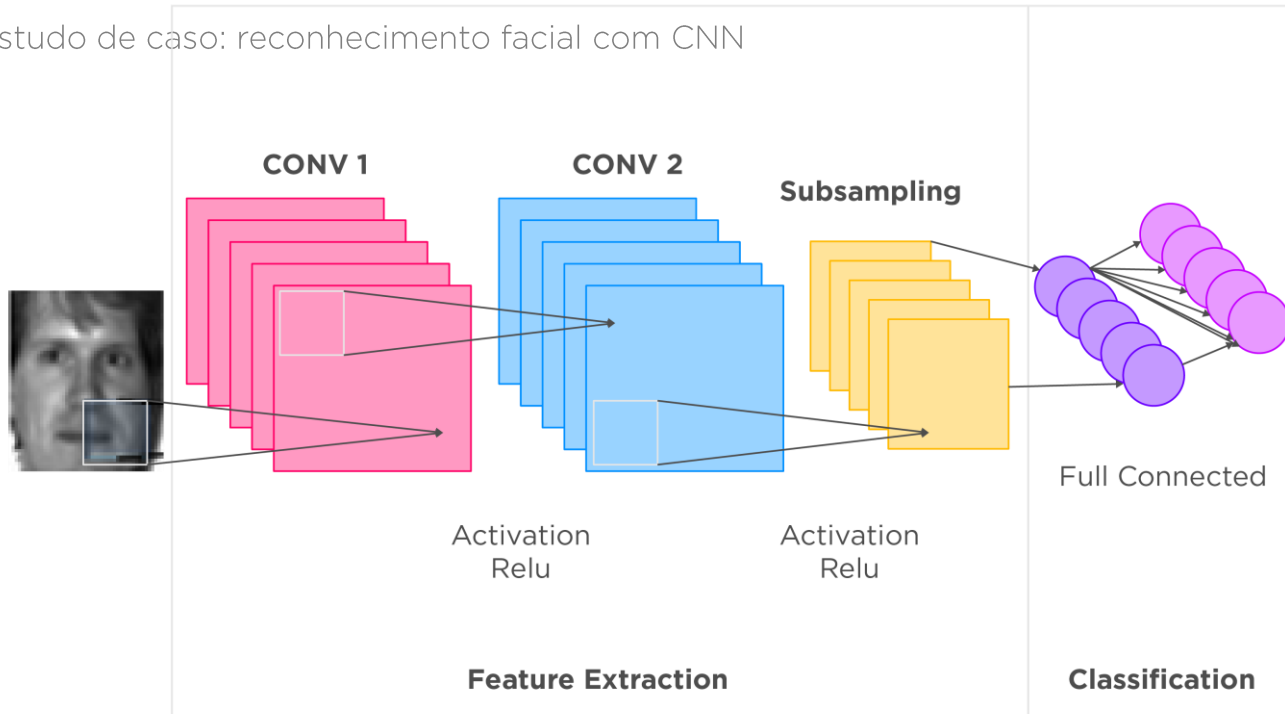
REDES NEURAIS **CONVOLUCIONAIS**

- Quando utilizar CNN?
- Por onde começar a resolver o problema com cnn?

DISCUSSÃO

REDES NEURAIS CONVOLUCIONAIS

- Estudo de caso: reconhecimento facial com CNN



REDES NEURAIS CONVOLUCIONAIS

- Estudo de caso: reconhecimento facial com CNN

CNN-based FR


DeepFace

Alignment: 2D, 3D

Input: RGB image 152x152

Output feature size: 4096


Parameters: ~ 120 million



Y. Taigman, M. Yang, M. Ranzato, and L. Wolf. Deepface: Closing the gap to human-level performance in face verification. In CVPR, 2014

REDES NEURAIS **CONVOLUCIONAIS**

- Estudo de caso: problema OCR Notas Fiscais
- Deep Learning de alta capacidade para classificar caracteres com ruído e defeitos de impressão.



• • • • • +
• • • • •
• + • REDES NEURAIS
+ • **CONVOLUCIONAIS**

|
+
HANDS ON #4:
**CLASSIFICAÇÃO DE IMAGENS COM
KERAS + TENSORFLOW E DATASET
MNIST**

REDES NEURAIS
CONVOLUCIONAIS

HANDS ON #5:
**CLASSIFICAÇÃO DE IMAGENS
COLORIDAS COM KERAS +
TENSORFLOW E DATASET CIFAR10**

OBRIGADO

FIAP

Copyright © 2020 | Professor Felipe Gustavo Silva Teodoro

Todos os direitos reservados. A reprodução ou divulgação total ou parcial deste documento é expressamente proibida sem o consentimento formal, por escrito, do(a) professor(a)/autor(a).



FIAP

