



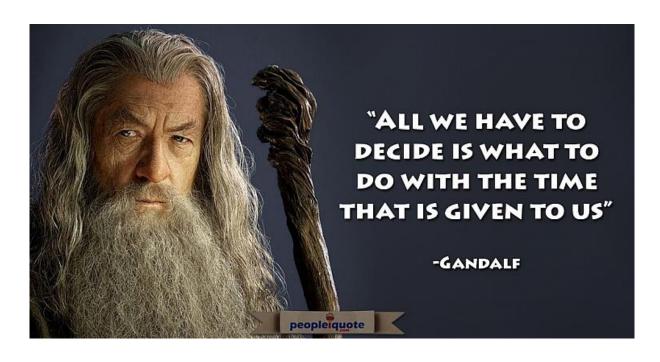
MACHINE LEARNING **E DEEP LEARNING**

ÀS VEZES, PRECISAMOS

COLOCAR O PASSADO PARA TRÁS....



NEM **SEMPRE...**



COMO TRATAR ESSE TIPO DE SITUAÇÃO

COM MACHINE E DEEP LEARNING?



COMO TRATAR ESSE TIPO DE SITUAÇÃO

COM MACHINE E DEEP LEARNING?

"This morning I took the dog for a walk."

Texto

Sinais médicos

Áudio

Sequência

Ordem

- A comida estava boa, não estava ruim.
- A comida estava ruim, não estava boa.

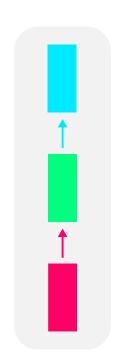
Dependência de longo prazo

• O tempo que passei na China foi muito legal e tive a oportunidade de aprender a falar _____, um idioma incrível.

Compartilhamento de parâmetros

• Um acidente pode ocorrer a qualquer momento.

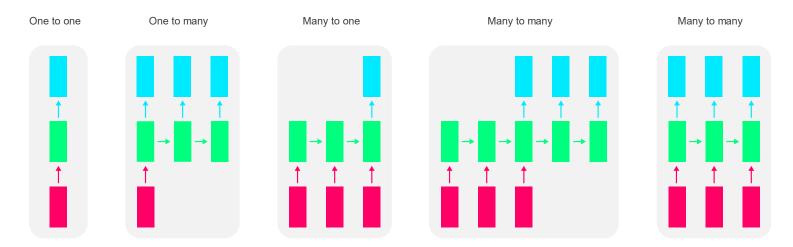
One to one



"Vanilla" Neural Network

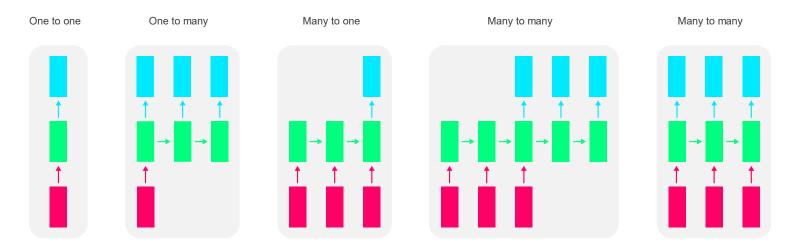
Fonte: Adaptado prof. Ahirton Lopes e School of IA

- SEQUÊNCIA DE PROCESSOS



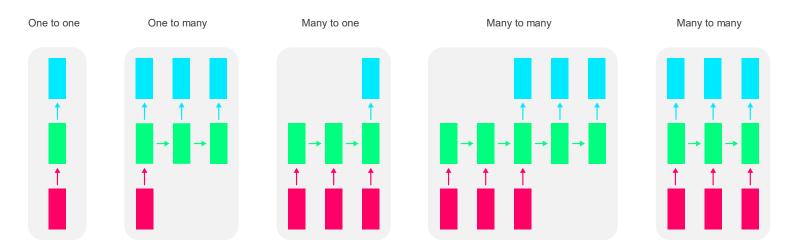
- Um para muitos por exemplo,
 legenda automatizada de imagens;
- Imagem -> sequência de palavras.

- SEQUÊNCIA DE PROCESSOS



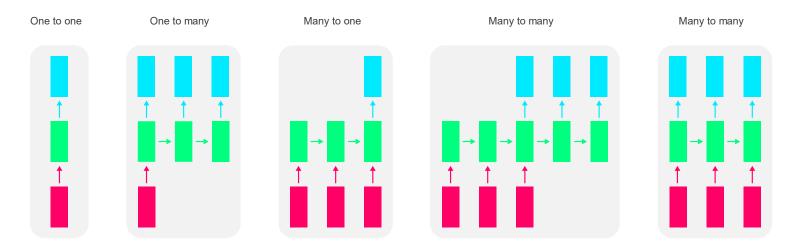
- Muitos para um por exemplo,
 Classificação de Sentimentos;
- Sequência de palavras -> sentimento.

- SEQUÊNCIA DE PROCESSOS



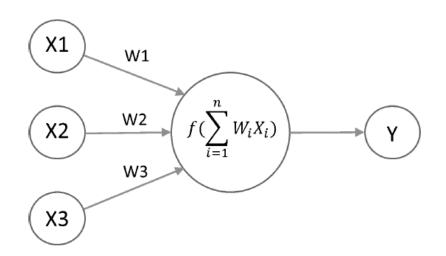
- Muitos para muitos por exemplo, Tradução por Máquina;
- Sequência de palavras -> sequência de palavras.

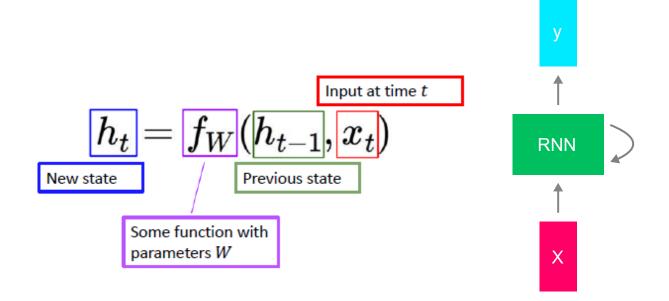
- SEQUÊNCIA DE PROCESSOS

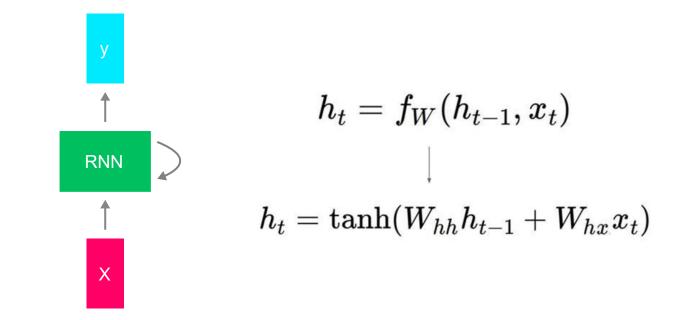


 Muitos para muitos - por exemplo,
 Classificação de vídeo no nível do quadro (frame level).

Neurônio Artificial Tradicional







$$h_{t-1} = \begin{bmatrix} h_{t-1}^{0} \\ \vdots \\ h_{t-1}^{i} \end{bmatrix} \xrightarrow{h_{t}} \begin{bmatrix} h_{t}^{0} \\ \vdots \\ h_{t}^{i} \end{bmatrix}$$

$$W_{hh} = \begin{bmatrix} w_{00} & \cdots & w_{0i} \\ \vdots & \ddots & \vdots \\ w_{i0} & \cdots & w_{ii} \end{bmatrix} = w_{ij} \in \mathbb{R}^{i \times i}$$

$$W_{hx} = \begin{bmatrix} w_{00} & \cdots & w_{0j} \\ \vdots & \ddots & \vdots \\ w_{i0} & \cdots & w_{ij} \end{bmatrix} = w_{ij} \in \mathbb{R}^{i \times j}$$

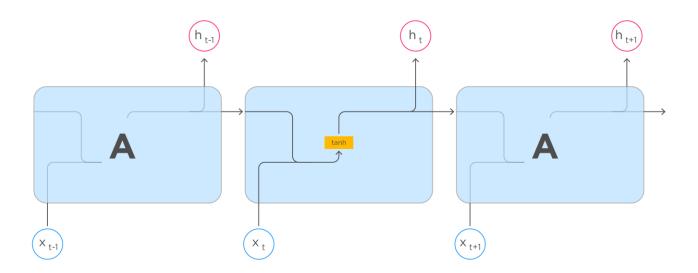
$$h_{t} = \tanh([W_{hh} \ W_{hx}] \begin{bmatrix} h_{t-1} \\ \chi_{t} \end{bmatrix})$$

$$h_t = \tanh(W_{hh}h_{t-1} + W_{hx}x_t)$$

$$W_{hh} = \begin{bmatrix} w_{00} & \cdots & w_{0i} \\ \vdots & \ddots & \vdots \\ w_{i0} & \cdots & w_{ii} \end{bmatrix} = w_{ij} \in \mathbb{R}^{i \times i}$$

$$\uparrow \\ x_t = \begin{bmatrix} x_t^0 \\ \vdots \\ i \end{bmatrix} \qquad W_{hx} = \begin{bmatrix} w_{00} & \cdots & w_{0j} \\ \vdots & \ddots & \vdots \\ w_{i0} & \cdots & w_{ij} \end{bmatrix} = w_{ij} \in \mathbb{R}^{i \times j} \qquad .$$

$$h_t = \tanh([W_{hh} \quad W_{hx}] \begin{bmatrix} h_{t-1} \\ \chi_t \end{bmatrix})$$

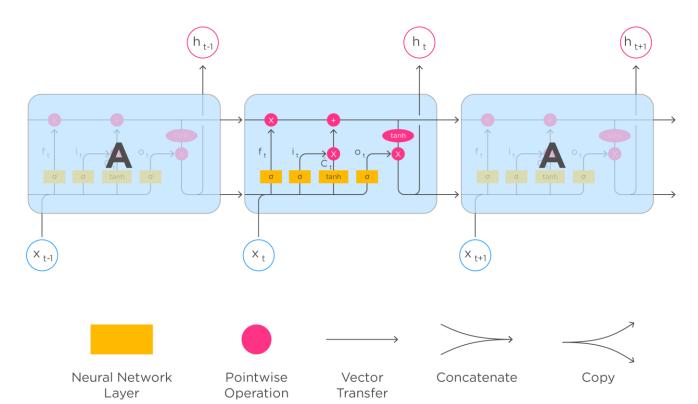


Fonte: http://colah.github.io/posts/2015-08-Understanding-LSTMs/

Problemas:

- Treino ruidoso devido ao Vanishing/Exploding gradiente
 - Backpropagation através do tempo (BPTT).
- Dificuldade em lidar com dependências de longo prazo
 - João entrou na sala. José também. Já é tarde e ambos estão atrasados. João disse oi para .
- Dificuldade em lidar com ruído

Teoricamente funciona, mas na prática é difícil treinar para problemas complexos



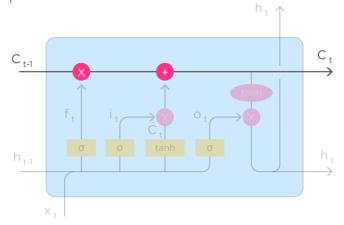
Cell State:

Resolve o problema do Vanishing/Exploding gradiente.

É mais do que uma simples conexão direta, pois as

informações propagadas são ponderadas pelas

entradas a cada tempo.



Forgot Gate:

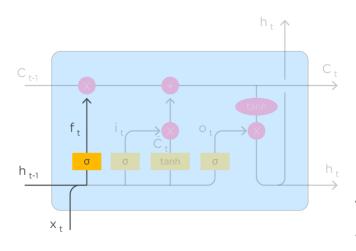
Decide qual informação que vem do **estado anterior** vai ser jogada fora

1: "Mantenha isso completamente"

O: "Esqueça isso completamente"

Exemplo:

Ao ler um novo substantivo a rede pode **esquecer** o gênero do substantivo recebido anteriormente.



$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] + b_f\right)$$

Input Gate:

Decide qual informação que vem da **entrada** vai ser inserida.

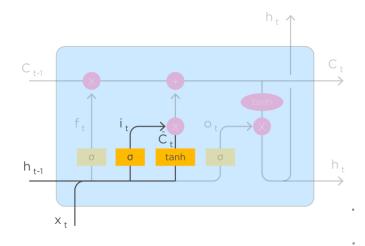
É combinado com o candidato a novo C

1: "Insira isso completamente"

O: "Deixe de lado"

Exemplo:

Ao ler um novo substantivo a rede pode **memorizar** o gênero.



$$i_t = \sigma \left(W_i \cdot [h_{t-1}, x_t] + b_i \right) \qquad \blacksquare$$

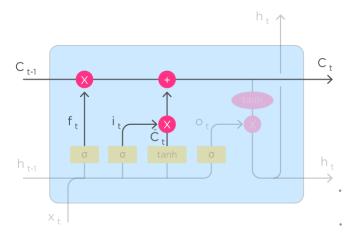
$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \qquad \cdot$$

Cell Update:

Multiplica-se o estado anterior por f_t , esquecendo algumas informações. Então adiciona-se $it*^{\circ\circ\circ}$, que é o novo candidato ponderado por quanto queremos lembrar

Exemplo:

Repassa ao estado celular o novo gênero encontrado



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

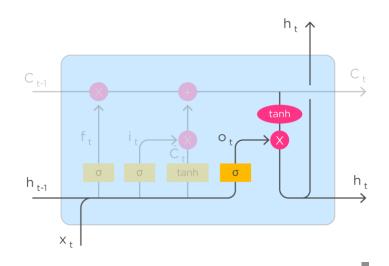
Output Gate:

Primeiro determina-se quais partes do **cellstate** será enviado para a saída.

Então usa-se uma tanh para gerar saídas que serão **multiplicadas** pelo *ot*.

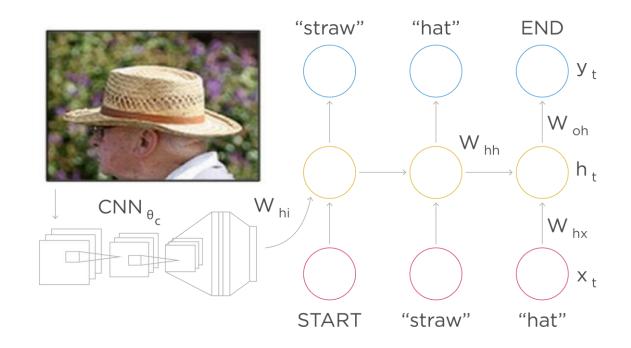
Exemplo:

Prediz que a próxima palavra irá seguir o novo gênero



$$o_t = \sigma (W_o [h_{t-1}, x_t] + b_o)$$

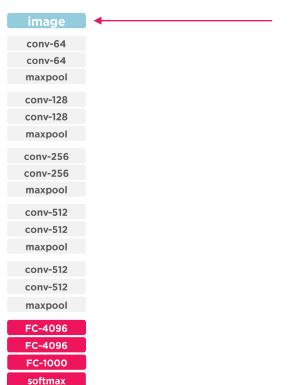
$$h_t = o_t * \tanh (C_t)$$



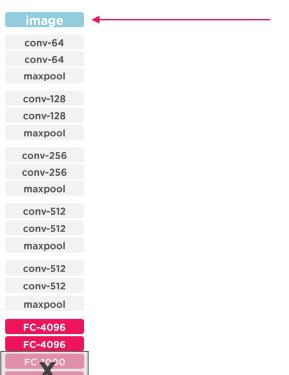
LEGENDA AUTOMATIZADA DE IMAGEM

Recurrent Neural Network "straw" "hat" **END** Уt W_{oh} W_{hh} h, CNN _{θc} Wh W_{hx} X_{t} **START** "straw" "hat" **Convolutional Neural Network**

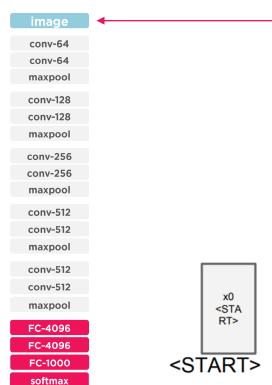


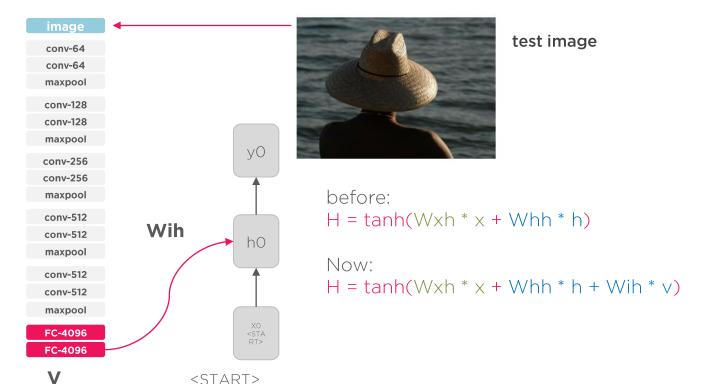


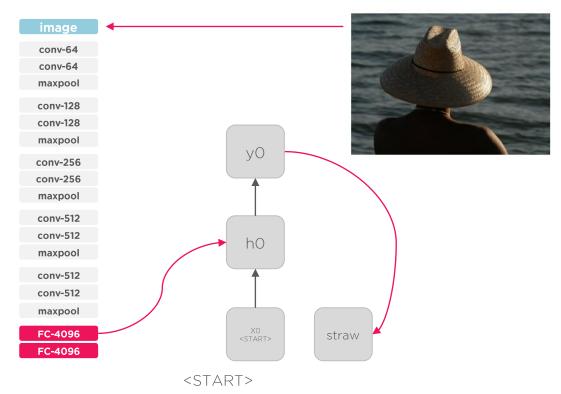


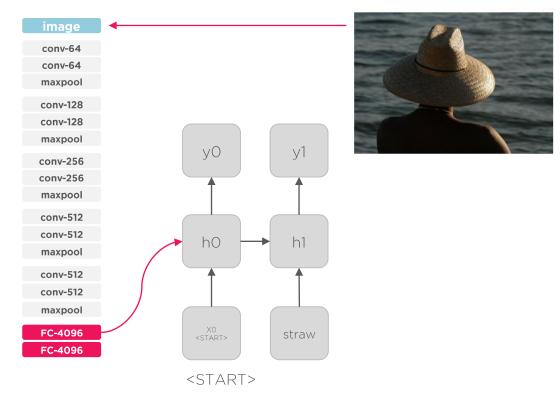


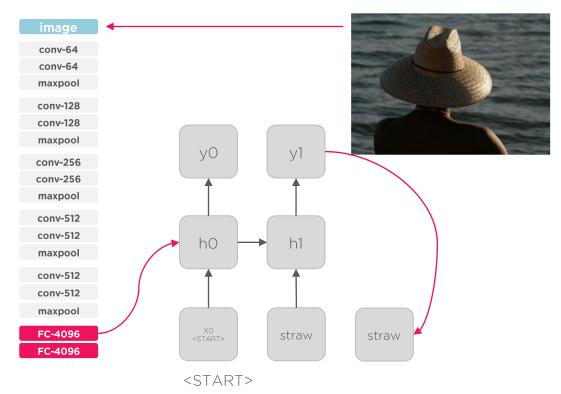


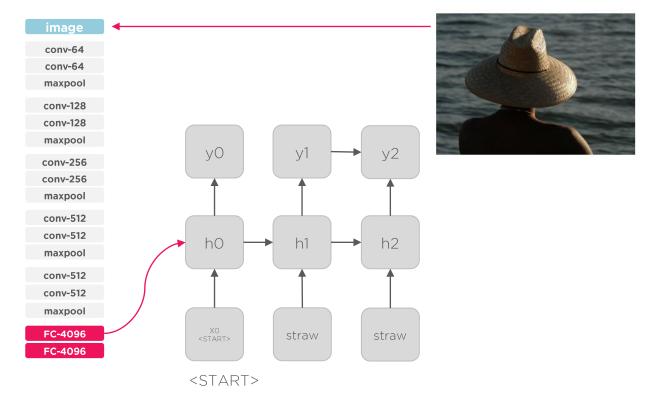












DEEP LEARNING -



A white teddy bear sitting in the grass;



A man riding a wave on top of a surfboard;



A cat sitting on a suitcase on the floor;

DEEP LEARNING -LEGENDAS AUTOMATIZADAS DE IMAGENS -

CASOS DE FALHA



A woman is holding a cat in her hand;



A person holding a computer mouse on a desk;



A bird is perched on a tree branch;

LSTM - **EXEMPLOS**

Demonstração LSTM Predição Simples de Séries Temporais:

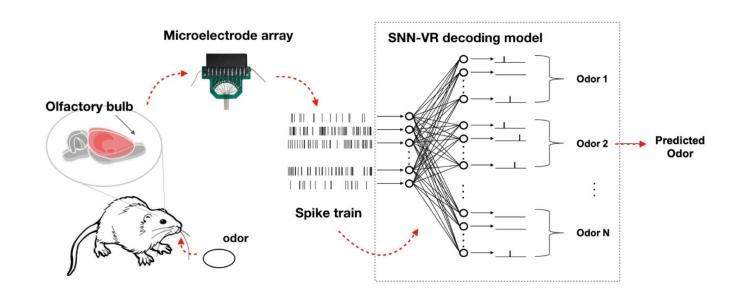
LSTM - EXEMPLOS

Demonstração LSTM para classificação de texto:

OUTROS MODELOS DE

DEEP LEARNING

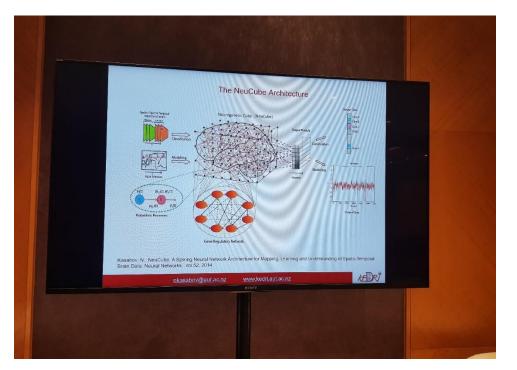
Spike Neural Networks



OUTROS MODELOS DE

DEEP LEARNING

Spike Neural Networks

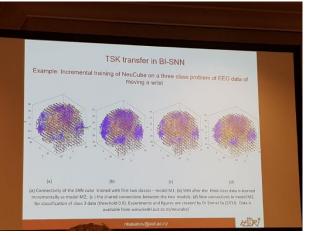


OUTROS MODELOS DE

DEEP LEARNING

Spike Neural Networks - NeuLab





OBRIGADO



Copyright © 2020 | Professor Msc. Felipe Teodoro

Todos os direitos reservados. Reprodução ou divulgação total ou parcial deste documento, é expressamente proibido sem consentimento formal, por escrito, do professor/autor.



#